

LLM 服务 Token 负载预测 与突发流量识别

——基于 BurstGPT 真实轨迹的 XGBoost 与 LSTM 比较

可复现研究包 · 论文初稿 · 2026-07-21

主任务：未来 15 分钟 | 粒度：Token/5min | Seed：42

摘要

生成式 AI 服务的容量压力同时取决于请求到达和输入、输出 Token 长度，因而仅预测请求数难以完整描述推理负载。本文使用 BurstGPT v2.0 请求轨迹，将 5,058,910 条清洗后主批次请求聚合为 34,848 个左闭右开的 5 分钟窗口，比较 Persistence、Seasonal Naive、XGBoost 与单层 LSTM 对未来 5、15、60 分钟总 Token 负载的预测，并用仅由训练集确定的固定 P95 容量阈值评价突发识别。为避免未来信息泄漏，所有切分按目标时间连续进行；在预测原点 t ，模型最后可用的完整窗口为 $t-5\text{min}$ ，目标为 $t+h$ ；scaler、阈值和统计特征仅在训练范围拟合，超参数只由验证集选择。15 分钟主测试中，LSTM 的 MAE 为 11,054.5 Token/5min，优于 Persistence (12,342.4)、Seasonal Naive (15,770.3) 和 XGBoost (16,464.4)。然而测试期只有 5 个固定阈值突发窗，四种模型的 F1 均为 0；XGBoost 的 AP 最高 (0.0113)，但只表明极弱的排序差异。批次 3 零样本迁移中 Persistence 的 15 分钟 MAE (43,838.2) 和 F1 (0.711) 均最优，显示模型排名会随时期和突发基率变化。结果说明总体点预测、固定容量超限和跨时期迁移是三个不同问题，不能用单一指标替代。

关键词： LLM serving；Token 负载；时间序列预测；突发识别；XGBoost；LSTM；可复现研究

1 引言

1.1 研究问题

LLM 推理服务的资源消耗不仅由请求数决定，也受 prompt 和生成长度、模型类型及服务形态共同影响。真实工作负载具有长尾、周期与突发性 [1–3]；KV cache、批处理和 prefill/decode 调度进一步使 Token 规模与有效容量直接相关 [4–9]。因此，提前获得短期 Token 负载信号可能帮助容量和调度，但这种系统意义不等同于已经证明节能或 SLO 收益。

本文回答三个问题：RQ1，四类方法在未来 15 分钟总体 Token 负载误差上有何差异？RQ2，总体 MAE 更低是否同时意味着训练集 P95 固定阈值下的突发识别更好？RQ3，结论在 5/60 分钟、最小特征消融和 BurstGPT 第 3 批零样本迁移中是否保持？

1.2 贡献

第一，本文定义了可审计的时间契约：窗口时间戳为左边界，目标时间决定切分，预测输入完整结束于原点之前。第二，在同一目标时间、阈值和测试集合上比较两个强基线、XGBoost 和小型 LSTM，同时区分点预测、阈值决策和排序能力。第三，提供逐窗预测、配置、验证日志、双工具图册、文件哈希和从干净环境复跑的 README。贡献是公平协议与证据链，而非新的网络结构。

2 相关工作

2.1 工作负载与服务系统

Resource Central 和 Azure Functions 研究显示，大型云负载同时具有异质性、周期性与集中性 [2,3]。Orca、PagedAttention、AlpaServe、Splitwise、DistServe 和 DynamoLLM 分别从批处理、显存、并行、多阶段部署与动态资源控制说明了 Token 长度和突发到达的系统价值 [4–9]。这些研究支持本文的应用动机，但它们主要评价 serving 系统，不直接回答真实轨迹上的预测精度。

2.2 预测方法

Persistence 和季节朴素法为短期惯性和周期性提供必要参照；M4 结果也提醒复杂模型不应被预设为必然优于强基线 [12]。XGBoost 通过正则化树提升学习非线性特征交互 [10]，LSTM 则通过门控状态表达长序列依赖 [11]。两者的公平比较必须共享输入可用时刻、目标切分和验证规则。

2.3 研究缺口

BurstGPT 提供真实生成式 AI 请求的相对时间、输入/输出 Token、模型和日志类型 [1]，但现有工作较少在同一轨迹上同时区分总体回归误差、固定容量阈值超限和跨时期迁移，并完整公开防泄漏证据。本文以该缺口为边界，不把相关性结果外推为基础设施收益的因果证明。

3 数据与时间切分

3.1 请求级清洗与 5 分钟聚合

主实验使用 `without_fails` 第 1、2 批；第 3 批只作零样本稳健性，`complete_1` 只作失败请求审计。清洗依次检查时间可解析、Token 数值、关键字段缺失、非负约束和全字段精确重复。批次 1 从 1,404,294 行减至 1,363,384 行，批次 2 从 3,784,213 行减至 3,695,526 行；删除项全部是全字段重复。由于原始数据没有请求 ID，精确重复删除可能误删并发同值请求，这是保留的局限。

对请求 i ，定义 $\text{total_tokens}_i = \text{request_tokens}_i + \text{response_tokens}_i$ 。令窗口宽度 $\Delta=5\text{min}$ ，第 k 个窗口为 $[b_k, b_{k+\Delta})$ ，则请求数和 Token 负载为：

$$N_k = \sum_i 1(b_k \leq \tau_i < b_{k+\Delta})$$

$$y_k = \sum_i 1(b_k \leq \tau_i < b_{k+\Delta}) \times \text{total_tokens}_i.$$

聚合后补齐完整规则网格，零请求窗保留且 $N_k=y_k=0$ 。人工抽样窗口重新回到请求级 Parquet 复算 Token、请求数、均值和构成，均与聚合表一致。

表 1 数据清洗与实验角色

批次	角色	原始请求	清洗后	删除	删除率
批次 1	主实验	1,404,294	1,363,384	40,910	2.91 %
批次 2	主实验	3,784,213	3,695,526	88,687	2.34 %
批次 3	零样本稳健性	4,956,058	4,805,535	150,523	3.04 %

注：BurstGPT v2.0；主实验使用批次 1/2，批次 3 仅作零样本稳健性；删除项为全字段精确重复。

3.2 目标时间 70/15/15 切分

公开时间为相对秒，因此转换为 UTC 仅用于单调索引，不能解释为真实日期、星期或节假日。完整序列按目标时间连续划分：训练 24,393 窗（70.0%）、验证 5,227 窗（15.0%）、测试 5,228 窗（15.0%）。特征暖启动使不同预测窗口的可训练样本略少，但验证和测试目标集合保持完全一致。任何样本都不随机打乱跨越边界。

表 2 主序列按目标时间的 70/15/15 切分

切分	5 分钟窗	占比	零窗	P95 突发窗	突发率
train	24,393	70.0%	3,323	1,220	5.001%
valid	5,227	15.0%	1,639	157	3.004%
test	5,228	15.0%	1,809	5	0.096%

注：BurstGPT 批次 1/2；单位为窗口数；P95=315,246.2 Token/5min，仅由训练集确定。

3.3 突发阈值

固定容量突发定义为 $y \geq q_{0.95}(y_{train})$ ；训练 P95 为 315,246.2 Token/5min，并原样应用于验证、测试和批次 3。训练、验证、测试的阈值突发窗分别为 1,220、157、5；测试正例率只有 0.0956%，因此 F1 的方差和可解释性必须与总体 MAE 分开。

4 模型、阈值与指标

4.1 时间契约与预测窗口

时间戳表示窗口左边界 $[t, t+5\text{min})$ 。对预测原点 t ，最后可用的完整窗口标记为 $t-5\text{min}$ ，目标标记为 $t+h$ ，其中 $h \in \{5, 15, 60\}$ 分钟。Persistence 直接复制 $y(t-5\text{min})$ ；Seasonal Naive 使用目标时刻前 24 小时的完整窗口。XGBoost 的全部历史量先 $\text{shift}(1)$ ，LSTM 的序列末端同样是原点前 5 分钟。专用校验脚本逐行检查 input end、origin 和 target 的间隔。

表 3 模型输入与选择边界

模型	在预测原点可用的输入	选择/拟合边界
Persistence	最后完整窗口 $y(t-5\text{min})$	无拟合
Seasonal Naive	目标时刻前 24h 窗口	无拟合
XGBoost	36 个历史滞后、滚动、构成和相对相位特征	12 候选；验证 MAE
LSTM	144×10 序列；输入结束于 $t-5\text{min}$	32 单元；验证 MAE/epoch

注：所有任务目标为 $t+h$ ；scaler、训练 P95 和拟合统计量只使用训练范围，测试集只在冻结后报告。

4.2 XGBoost

XGBoost 使用 36 个仅由历史可得特征：8 个 Token 滞后、多个滚动均值/标准差/最大值、请求和平均输入输出 Token 的滞后统计、历史 GPT-4/API 占比，以及仅基于相对秒数的日/周正余弦相位。每个窗口评估 12 个候选，选择指标只有验证集 MAE；最终参数冻结后在训练+验证范围重拟合，测试只预测一次。SHAP 只解释冻结模型，不参与选参。

4.3 LSTM

LSTM 输入为 144×5 分钟（12 小时）的 10 变量序列，包括 Token、请求量、平均输入/输出 Token、历史 GPT-4/API 占比和相对日/周相位。网络为单层 LSTM(32, dropout=0.1) 接 Dense(1)，共 5,537 个参数；损失为 MAE，batch size 64，不打乱序列。特征 scaler 只拟合训练序列实际使用的唯一输入行，目标 scaler 只拟合训练标签；最佳 epoch 由验证 MAE 决定，15 分钟为第 45 epoch。最终负预测裁剪为 0；XGBoost 未对称裁剪，这一差异在局限中披露。

4.4 指标与统计推断

对 n 个目标, $MAE=n^{-1}\sum|y_i-\hat{y}_i|$, $RMSE=\sqrt{n^{-1}\sum(y_i-\hat{y}_i)^2}$, $sMAPE=100\cdot n^{-1}\sum[2|y_i-\hat{y}_i|/(|y_i|+|\hat{y}_i|+\epsilon)]$ 。突发指标为 $Precision=TP/(TP+FP)$ 、 $Recall=TP/(TP+FN)$ 和 $F1=2PR/(P+R)$;
AP 使用按预测分数排序的非插值平均精度, 不称作梯形 PR-AUC。95% 区间按合成 UTC 日进行整块 Bootstrap, 主结果 1,000 次、批次 3 为 500 次, seed=42。

5 总体准确率

表 4、图 11、图 13 : 15 分钟主结果

观察到什么。 LSTM 在主测试期的总体 MAE 最低, 而 XGBoost 没有优于两个强基线。**量化证据。** LSTM MAE 为 11,054.5 Token/5min, 较 Seasonal Naive 改善 29.9%; Persistence 为 12,342.4, XGBoost 为 16,464.4。**可能原因。** 12 小时序列可能更直接吸收局部形状和水平变化, 而有限训练规模、手工滞后特征及测试期负载下移可能削弱树模型的相对优势。**不应过度推断。** 单一匿名轨迹和单一测试时期不能证明 LSTM 一般优于 XGBoost; XGBoost 的相对劣势也不应表述为训练失败。


表 4 BurstGPT 批次 1/2 的 15 分钟主测试总体结果

模型	MAE	RMSE	sMAPE	较季节基线	AP
Persistence	12,342.4	37,224.4	74.8%	21.7%	0.0054
Seasonal Naive	15,770.3	41,891.0	91.4%	0.0%	0.0068
XGBoost	16,464.4	34,748.3	130.2%	-4.4%	0.0113
LSTM	11,054.5	30,904.2	88.1%	29.9%	0.0108


注: $n=5,228$; MAE/RMSE 单位为 Token/5min; AP 为非插值 average precision。模型按验证证据冻结。

15-minute forecast accuracy and burst-detection performance

Same 5,228 test target windows and fixed train P95; lower MAE and higher F1 are better

**图 13 15 分钟总体 MAE 与固定阈值 F1 (BurstGPT 批次 1/2 测试集)****Actual and 15-minute-ahead forecasts in a representative test week**

Median-total complete seven-day window: 1970-04-19 to 1970-04-25; Token/5-min

**图 11 15 分钟预测在客观选择代表周的曲线对比 (Token/5min)**

代表周曲线显示所有模型能跟随普通负载的大致方向，但尖峰幅度和局部相位仍有明显差异。该图按完整测试周总负载最接近中位数的客观规则选择，不是为了突出某个模型。

6 突发识别

表 5、图 12、图 14、图 15：固定训练 P95

观察到什么。 四种方法在主测试固定阈值下都没有命中真实突发，总体 MAE 最优与突发识别最优不一致。**量化证据。** 测试仅 5 个正例，四模型 F1 均为 0；XGBoost AP 为 0.0113、LSTM 为 0.0108，且 XGBoost 仍有 2 个假阳性。**可能原因。** 训练到测试的绝对负载明显下移，使 315,246.2 Token/5min 落在测试极端尾部；极少正例也使 PR 曲线离散。**不应过度推断。** 零 F1 不意味着模型毫无排序信息，但如此低的 AP 也不足以支持可部署的固定阈值检测。

表 5 BurstGPT 批次 1/2 的 15 分钟固定 P95 突发结果

模型	P	R	F1	AP	TP/FP/FN/TN
Persistence	0.000	0.000	0	0.0054	0/5/5/5218
Seasonal Naive	0.000	0.000	0	0.0068	0/4/5/5219
XGBoost	0.000	0.000	0	0.0113	0/2/5/5221
LSTM	0.000	0.000	0	0.0108	0/0/5/5223

注: $n=5,228$, 真实突发窗=5; P/R 分别为 Precision/Recall; 阈值为训练集 P95=315,246.2 Token/5min, 未使用测试标签调整。

Forecast behavior around the largest test burst

Objective selection rule: maximum actual test load at 1970-05-01T16:00:00+00:00; fixed train-only P95 shown




图 12 最大真实负载附近预测与训练 P95 (Token/5min)

Precision-recall curves for 15-minute fixed-P95 burst detection

Five positive windows among 5,228 test targets; PR-AUC is reported as average precision




图 14 15 分钟突发排序的 Precision-Recall 曲线

最大真实负载附近的局部图显示，预测曲线均没有在正确时刻越过训练 P95。混淆矩阵将 TP/FP/FN/TN 全部显式报告，避免准确率被大量真负例主导。

7 误差、消融与稳健性

表 6、图 16–18：分组误差

观察到什么。 突发窗误差远高于普通窗，并随相对日/周相位和服务构成变化。**量化证据。** 表 6 同时报告各组样本数、MAE、RMSE 和 sMAPE；非突发 MAE 最低的是 LSTM，真实突发窗 MAE 最低的是 XGBoost。**可能原因。** 长尾目标、服务构成变化和负载水平漂移共同改变局部误差。**不应过度推断。** 目标时刻 GPT-4/API 占比只用于事后分组，不能作为在线可用的未来特征，也不能支持因果解释。

表 6 BurstGPT 批次 1/2 的 15 分钟突发/非突发分组误差

模型	分组	n	MAE	平均偏差
Persistence	突发	5	294,000.0	-294,000.0
Seasonal Naive	突发	5	292,000.0	-292,000.0
XGBoost	突发	5	281,000.0	-281,000.0
LSTM	突发	5	303,000.0	-303,000.0
Persistence	非突发	5,223	12,100.0	265.0
Seasonal Naive	非突发	5,223	15,500.0	-1,440.0
XGBoost	非突发	5,223	16,200.0	7,610.0
LSTM	非突发	5,223	10,800.0	-3,420.0

注：MAE 和平均偏差单位为 Token/5min；偏差=预测-真实；分组只用于事后诊断，不进入训练或模型选择。

15-minute forecast error in non-burst and burst target windows

Panels use separate, explicitly labeled zero-based scales because burst-window errors are much larger




图 16 真实突发与非突发窗口的 15 分钟 MAE (Token/5min)

表 6a : XGBoost 最小消融

观察到什么。 完整 36 特征在验证集排名第一，但缩减特征组在测试期反而有更低 MAE。**量化证据。** 验证 MAE 依次为 23,925、25,020、26,458；测试 MAE 却为 16,464、15,264、13,881。**可能原因。** 历史服务构成与目标负载之间的关系跨时期变化。**不应过度推断。** 测试排名不能回写为新的特征选择；主模型仍是验证集选定的完整特征组，消融只作有限诊断。

表 6a XGBoost 15 分钟最小特征消融

特征组	切分	特征数	MAE	验证名次	入选
完整特征	valid	36	23,900	1	是
去服务构成	valid	30	25,000	2	否
滞后+相对相位	valid	12	26,500	3	否
完整特征	test	36	16,500	1	是
去服务构成	test	30	15,300	2	否
滞后+相对相位	test	12	13,900	3	否

注：BurstGPT 批次 1/2；MAE 单位 Token/5min。测试结果不得回写为新选择。

表 7：BurstGPT 第 3 批零样本迁移

观察到什么。 跨时期模型排名发生变化，Persistence 同时取得最低 MAE 和最高固定阈值 F1。**量化证据。** 15 分钟 MAE/F1 为 Persistence 43,838.2/0.711、LSTM 53,509.2/0.520、XGBoost 61,795.3/0.509、Seasonal Naive 120,193.3/0.0377。**可能原因。** 第 3 批的负载水平、突发基率和构成不同，局部惯性比冻结模型的训练期关系更稳定。**不应过度推断。** 这是不使用批次 3 拟合、scaler 或选择的外部零样本检验，不等于批次 3 内重训后的可达到性能。

表 7 BurstGPT 第 3 批的 15 分钟零样本跨时期结果

模型	MAE	RMSE	sMAPE	F1	AP
Persistence	43,800	142,000	65.4%	0.711	0.671
Seasonal Naive	120,000	282,000	108.0%	0.038	0.068
XGBoost	61,800	163,000	87.1%	0.509	0.475
LSTM	53,500	157,000	77.7%	0.520	0.625

注: $n=31,389$; MAE/RMSE 单位 Token/5min; 模型、scaler 和 P95 全部来自批次 1/2, 批次 3 拟合/选择行数为 0。

W5-PY-10 BurstGPT-3 external zero-shot robustness

Models and the train-1/2 P95 are transferred without fitting or selecting on batch 3




图 19 BurstGPT 第 3 批零样本 5/15/60 分钟稳健性: 总体 MAE 与突发 F1

8 局限与意义

第一, 真实年份和星期语义不可得, 相对日/周相位不能解释为真实工作日或节假日。第二, 主测试只有 5 个固定阈值正例, 突发指标高度不稳定。第三, 无请求 ID 时的精确重复删除可能误删并发同值请求。第四, LSTM 对负预测裁剪而 XGBoost 不裁剪, 处理不完全对称。第五, 只比较一个树模型和一个小型序列网络, 未穷尽概率预测、在线更新和自适应阈值。

尽管如此, 研究给出一个可审计结论: 面向容量规划时必须明确区分平均误差、绝对容量超限和分布漂移。低 MAE 可以帮助普通时段的资源信号, 但不能自动转化为突发告警能力; 外部批次中强基线的回归, 说明部署前应进行滚动回测和基线守护。

9 结论

在严格无泄漏协议下，LSTM 是 BurstGPT 主测试 15 分钟总体 MAE 最优模型，但四种方法对 5 个固定 P95 突发窗均未命中，XGBoost 仅在 AP 排序上略高。批次 3 零样本结果又由 Persistence 主导，证明总体预测、固定容量突发和跨时期稳健性是不同评价维度。本文不据测试集重选模型或阈值；最终价值在于公开这些边界以及可按 README 重建的证据链。

可复现性声明

环境、命令、随机种子、原始文件位置和产物映射见根目录 `README.md`；时间契约由 `scripts/validate_temporal_contract.py` 独立核验；最终表图及 SHA-256 见 `artifacts/final/manifest_sha256.csv`；干净复跑和旧结果差异见 `docs/reproducibility_report.md`。原始 CSV 根据数据许可由使用者自行下载，不随研究包再分发。

参考文献

- [1] Wang Y, Chen Y, Li Z, et al. BurstGPT: A Real-World Workload Dataset to Optimize LLM Serving Systems. KDD, 2025. doi:10.1145/3711896.3737413.
- [2] Cortez E, Bonde A, Muzio A, et al. Resource Central: Understanding and Predicting Workloads for Improved Resource Management in Large Cloud Platforms. SOSP, 2017:153–167. doi:10.1145/3132747.3132772.
- [3] Shahrads M, Fonseca R, Goiri I, et al. Serverless in the Wild: Characterizing and Optimizing the Serverless Workload at a Large Cloud Provider. USENIX ATC, 2020:205–218.
- [4] Yu G I, Jeong J S, Kim G W, et al. Orca: A Distributed Serving System for Transformer-Based Generative Models. OSDI, 2022:521–538.
- [5] Kwon W, Li Z, Zhuang S, et al. Efficient Memory Management for Large Language Model Serving with PagedAttention. SOSP, 2023:611–626. doi:10.1145/3600006.3613165.
- [6] Li Z, Zheng L, Zhong Y, et al. AlpaServe: Statistical Multiplexing with Model Parallelism for Deep Learning Serving. OSDI, 2023:663–679.
- [7] Patel P, Choukse E, Zhang C, et al. Splitwise: Efficient Generative LLM Inference Using Phase Splitting. ISCA, 2024:118–132. doi:10.1109/ISCA59077.2024.00019.

- [8] Zhong Y, Liu S, Chen J, et al. DistServe: Disaggregating Prefill and Decoding for Goodput-optimized Large Language Model Serving. OSDI, 2024:193–210.
- [9] Stojkovic J, Zhang C, Goiri I, et al. DynamoLLM: Designing LLM Inference Clusters for Performance and Energy Efficiency. HPCA, 2025. doi:10.1109/HPCA61900.2025.00102.
- [10] Chen T, Guestrin C. XGBoost: A Scalable Tree Boosting System. KDD, 2016:785–794. doi:10.1145/2939672.2939785.
- [11] Hochreiter S, Schmidhuber J. Long Short-Term Memory. Neural Computation, 1997, 9(8):1735–1780. doi:10.1162/neco.1997.9.8.1735.
- [12] Makridakis S, Spiliotis E, Assimakopoulos V. The M4 Competition: 100,000 Time Series and 61 Forecasting Methods. International Journal of Forecasting, 2020, 36(1):54–74. doi:10.1016/j.ijforecast.2019.04.014.